

可信数据空间: 平台工具调研文档

| ■ 创建时间 | @2025年7月28日 15:56 |
|--------|-------------------|
| ■标签 | 调研 |
| ■ 状态 | 进行中 |

开源协议

| MIT | MIT 许可证,最宽松开源协议,几乎无限制地允许修改、商用与再分发。 |
|--------------|--|
| LGPL 2.1 | LGPL(宽松通用公共许可证) ,允许在闭源项目中链接使用,只要修改的部分开源即可。 |
| Apache 2.0 | Apache 2.0 是非常商业友好的协议,允许修改、再分发、商用,且附带专利权授权。 |
| AGPL | AGPL (Affero GPL),要求部署服务也需开源,但本地部署可用;不建议用于对外提供服务的商业项目。 |
| BSD 3-Clause | BSD 许可证 允许自由使用、修改和再发布,仅要求保留版权声明。 |

一、背景与目标

当前可信数据空间平台已具备多源数据汇聚、权限控制与数据安全能力,为进一步提升平台对多模态数据的处理与智能分析能力,有必要引入开源、可商用、可控的加工

可信数据空间:平台工具调研文档 1

与建模工具,构建完善的数据资产流转链路。

本调研围绕平台功能完善目标,聚焦图像、视频、文档等数据类型的处理需求,评估可落地的工具与模型能力,为可信空间在实际业务中实现数据可用不可见提供能力支撑,助力平台形成从数据加工、标注、建模、图谱构建到智能问答的完整闭环能力。

二、端到端业务场景概述

1. 场景工作流

- 1. 无人机或监控设备采集低空图像/视频
- 2. 平台对视频抽帧、图像脱敏、对象检测等进行预处理
- 3. 通过标注工具进行多目标标注(如飞行器、人员、烟雾等)
- 4. 使用开源模型进行训练,产出本地可控模型
- 5. 非结构化登记文档(如许可单)通过 OCR、结构化工具处理
- 6. 所有对象入图谱(组织、设备、事件、责任人等)
- 7. 接入大模型实现图谱增强问答与调度分析

2. 场景

graph TD

A[数据采集设备] → B[视频/图像/文档上传]

- B → C[预处理: 抽帧 / 脱敏 / OCR]
- C → D[人工辅助标注 (CVAT / Label Studio)]
- D → E[模型训练(YOLO / ResNet / SAM)]
- $E \rightarrow J$
- B → G[结构化文档 (PaddleOCR)]
- G → H[实体抽取 / 关系抽取 (HanLP / OpenNRE)]
- H → I[知识图谱构建 (Neo4j)]
- I → J[问答服务 (LangChain + 私有LLM)]

三、工具及模型选型调研

可信数据空间:平台工具调研文档

1. 视频与图像处理工具

• FFmpeg:

。 视频抽帧、关键帧提取、截图

。 许可协议: LGPL 2.1

。 仅用于抽帧、裁剪等基础处理完全合规

• OpenCV + MTCNN:

。 用于图像中人脸检测与模糊打码

。 适用场景:图像/视频中人像脱敏处理

。 商用许可: MIT (安全可控)

2. 标注工具

CVAT (Computer Vision Annotation Tool)

。 功能: 支持图像/视频多目标标注, 含跨帧跟踪、插值

。 模型集成:支持调用YOLO/SAM进行预标注

。 格式支持: COCO、YOLO、CVAT XML 等

。 商用许可: MIT

。 中文支持: 社区已提供语言包, 可内嵌部署

Label Studio

。 功能:适合文档类字段、结构化文本标注

。 配合 OCR 输出进行表单、证件、票据的区域标注

。 商用许可: Apache 2.0

3. OCR 与结构化文档处理

PaddleOCR

。 功能: 中英文混合 OCR、竖排、手写、票据、身份证等

。 商用许可: Apache 2.0

4. 模型训练与目标检测

DeepLabV3+

- 。 经典的语义分割模型,精度高
- 。 商用许可: Apache 2.0

SAM (Segment Anything Model)

- 。 用于高质量 mask 分割,提升精细标注效率
- 。 商用许可: Apache 2.0

• ResNet / MobileNet

- 。 用于图像分类、场景识别等任务
- 。 商用许可: Apache 2.0

5. 文本与实体关系处理

HanLP

- 。 功能:中文命名实体识别、依存句法、词法分析
- 。 商用许可: Apache 2.0

OpenNRE

- 。 功能: 关系抽取框架
- 。 结合实体识别提取"归属-责任人"等语义关系
- 。 商用许可: MIT

6. 图谱构建与问答增强

- Neo4j Community Edition
 - 。 用于事件图谱、设备图谱、责任图谱等构建
 - 。 Cypher 查询 + 可视化插件丰富
 - 。 商用建议: 非 SaaS 使用场景 AGPL 可接受

ECharts Graph / Vue-Graph

- 。 用于图谱结构前端展示与交互操作
- 。 商用许可: MIT

• LangChain / LlamaIndex

。 实现图谱+文档增强问答(GraphQA + 文档RAG)

- 。 可接入私有大模型如 ChatGLM、通义千问
- 。 商用许可: MIT

四、小结与推荐组合

本平台场景下,推荐构建如下工具链组合:

• 数据处理层: FFmpeg + OpenCV + PaddleOCR

• 标注层: CVAT (图像/视频) + Label Studio (文档)

• 训练层: YOLOv8 + SAM + ResNet

• 实体知识层: HanLP + OpenNRE + Neo4j

• 可视化与智能层: ECharts + LangChain + 私有LLM

可信数据空间:平台工具调研文档